Assignment 3

Usability testing: Chiaro, scaffolding del prompting per over 60

Impostazione dello studio sommativo su T1, T2 e T3, con confronto tra Chiaro e una chat libera su T1 e T2

Studente: Lucageneroso Cammarota

Versione corrente: Rev. 7 · 10 novembre 2026

Per visualizzare il prototipo, cliccare qui.

Versionamento del documento

Rev.	Data	Autore	Prototipo valutato	Modifiche
1	25/10/2026	LC	Prima versione	Implementazione iniziale
2	da completare	LC	—	Revisione intermedia: storico da completare dall'autore
3	5 nov 2026	LC	App.tsx e index.css, versione precedente	Valutazione euristica sul codice: 18 problemi aperti (P-1...P-23), cinque corretti.
4	9 nov 2026	LC	App.tsx e index.css con le correzioni di Figma Make	Stato di P-1...P-23 verificato nel codice (8 aperti, 15 corretti); copertina e versionamento; segnaposto nel testo salvato di T1 = elemento mancante; pannello osservatore senza gesto sul logo.
5	9 nov 2026	LC	App.tsx e index.css TERZA CORREZIONE	Verificate nel codice le correzioni di P-3, P-6, P-17, P-20 e P-21: 5 problemi aperti (P-1, P-3, P-6, P-10, P-23), 18 corretti; nessun problema aperto altera le misure. Aggiornati limiti noti e pannello osservatore.
6	10 nov 2026	LC	App.tsx e index.css come alla Rev. 5 (nessuna nuova correzione al codice)	Allineamento con Assignment 1 e 2: tabella di raccordo H-xx / F4-x / A-x / P-xx (sezione 2), domanda B15 sulla postura d'uso, copertura C19…C27 con le righe C10, C11, C15, C28, C29 e C30, rimando al walkthrough del Design, deviazione dalla traccia (limite 5)
7	10 nov 2026	LC	App.tsx e index.css con T3 (F7, F9, vista di Marta)	T3 «Capire un avviso» realizzato nel prototipo e verificato nel codice: P-1 chiuso e cinque problemi nuovi (P-24…P-28), quindi 9 problemi aperti e 19 corretti. T3 entra nello studio solo su Chiaro, in un terzo blocco di circa 10 minuti, con US09 e US11 (US16 resta fuori): scheda e criteri di T3, campi della scheda dell'osservatore, copione di Marta, sessione di circa 75 minuti. Raccordo H-13…H-16 e walkthrough W-9…W-13 (Design, Allegato A)

Assignment 3 – Usability testing: Chiaro, scaffolding del prompting per over 60

Sommario

Assignment 3 – Usability testing: Chiaro, scaffolding del prompting per over 60 3
1. Premessa, ambito e limiti 4
2. Valutazione euristica del prototipo finale 5
3. Specifiche di usabilità e task selezionati 13
4. Obiettivi e disegno dello studio 15
5. Partecipanti e questionari 16
6. Variabili, ipotesi nulle e test 18
7. Istruzioni e task 19
8. Raccolta dei dati 21
9. Validità ecologica 23
10. Analisi dei risultati, copertura e replicabilità 24
11. Riferimenti e appendice 26

1. Premessa, ambito e limiti

Questo documento imposta lo studio di usability testing sommativo di Chiaro su tutti e tre i task progettati: T1 e T2 con un confronto tra Chiaro e una chat libera senza scaffolding, T3 solo su Chiaro. Il lavoro è individuale e non esiste un gruppo valutatore: progettista, osservatore e analista coincidono. La traccia richiede almeno l'impostazione dello studio: l'impostazione qui descritta è valida anche senza sessioni con partecipanti.

Dalla valutazione formativa alla valutazione sommativa. Il documento formalizza il passaggio dalla valutazione formativa alla progettazione della valutazione sommativa (Summative Evaluation) su otto partecipanti (Rosson e Carroll, 2002). La prima, finalizzata a correggere l'interfaccia mentre è ancora modificabile, comprende le ispezioni euristiche (sezione 2 di questo documento; sezioni 6 e 9 e Allegato A, il walkthrough, del Design) e il pilota su tre partecipanti descritto nella sezione 10, che precede lo studio. La seconda, impostata nelle sezioni 3–10, misura se Chiaro raggiunge le specifiche di usabilità rispetto a una condizione di confronto.

Che cosa si testa. Il prototipo funzionante realizzato in Figma Make, con le schermate Home, Modelli di lettera, Domanda guidata, La tua richiesta, Bozza, Dettatura, Taccuino, Descrivi l'avviso, Risposta, Sedia accanto (invito, ambito e conferma) e Vista di Marta (simulata). L'assistente non è un modello reale: i testi sono scritti a priori.

- **T1, scrivere una lettera di disdetta** (scenario 1, Rosa): mini-intervista, richiesta, bozza, «Non è quello che volevo», salvataggio.
- **T2, chiedere un'informazione a voce** (scenario 2, Giuseppe): dettatura, controllo della trascrizione, chiusura della conversazione, cancellazione di una voce da «Cosa ricordo».
- **T3, verificare una risposta e condividerla** realizzato nel prototipo a partire da questa revisione (F7 «Risposta strutturata» e F9 «Sedia accanto»): descrizione dell'avviso, risposta in quattro sezioni, apertura di una fonte, invito a Marta, scelta dell'ambito, riquadro «Cosa vede Marta», revoca, vista simulata di Marta e suggerimento. Entra nello studio solo su Chiaro, perché la chat libera non ha un equivalente della Sedia accanto, e permette di verificare US09 e US11 e i problemi H-13…H-16 del documento di Design. US16 resta fuori: il prototipo non ha una risposta volutamente errata o non verificabile.

Simulazione dell'assistente (Wizard of Oz). Le risposte dell'assistente sono pre-configurate: il comportamento di un modello linguistico è sostituito da testi scritti in anticipo dal progettista. È l'applicazione della tecnica di prototipazione Wizard of Oz (Kelley, 1984; Dahlbäck et al., 1993), in cui un «mago» fa le veci di un sistema che ancora non esiste. Qui il mago non risponde dal vivo: ha scritto in anticipo le risposte e le ha collegate alle scelte del partecipante, per cui si tratta di una variante a copione e non di un Wizard of Oz puro. Il partecipante è informato che l'applicazione è simulata (sezione 7). La tecnica consente di valutare l'usabilità percepita dell'interazione prima di integrare un LLM reale, senza che la variabilità delle risposte confonda la misura; non consente di valutare la qualità delle risposte di un modello reale (si veda la tabella seguente).

Che cosa è reale e che cosa è simulato nel test

Elemento	Nel test	Effetto sulla misura
Microfono	Simulato: «Fine» restituisce sempre la frase fissa, e il partecipante legge la frase da una scheda; nella risposta finale «Parla» non inserisce testo e il partecipante scrive; la barra del livello sonoro si anima durante l'ascolto ma non misura l'audio	Gli errori di trascrizione sono scritti a priori: US05 misura solo se l'utente corregge un errore segnalato
Assistente	Testi scritti a priori, adattati alle risposte date in T1 e fissi in T2 e T3: la risposta di T3 non dipende dal testo scritto dal partecipante	La qualità della bozza e della risposta all'avviso non è oggetto di misura
Memoria	Una voce precaricata («Il tuo medico è il dottor Neri»)	US10 misura la cancellazione, non l'apprendimento del sistema
Sedia accanto e Marta	Simulate sullo stesso tablet: link, QR e codice («MARTA-4826») sono fissi e non vengono inviati; Marta è l'osservatore, che passa alla vista di Marta e scrive un suggerimento di copione	US11 misura che cosa il partecipante capisce di ciò che è condiviso e se revoca, non un invito reale né la condivisione asincrona da un'altra casa
Chat libera	Un'applicazione di chat reale, con dettatura della tastiera del tablet	Il microfono della condizione di confronto è reale e quello di Chiaro è simulato

Limiti dichiarati. (1) Progettista e valutatore coincidono: rischio di conferma, ridotto con soglie fissate prima dei dati, un protocollo scritto e identico per tutti e la codifica di US01 fatta anche da un secondo valutatore. (2) Il campione è piccolo e non probabilistico. (3) T3 è valutato solo su Chiaro, senza condizione di confronto e con Marta simulata dall'osservatore. (4) La durata delle sessioni non consente di osservare l'uso ripetuto nei giorni. (5) Deviazione dalla traccia: la traccia prevede la valutazione del prototipo di un altro gruppo, mentre qui si valuta il prototipo dell'autore.

2. Valutazione euristica del prototipo finale

Sul prototipo finale (App.tsx e index.css) restano 9 problemi aperti: 1 di gravità 3 (P-24), 2 di gravità 2 e 6 di gravità 1; diciannove problemi sono corretti (gravità 0), quattordici dei quali dopo la Rev. 3. La valutazione è fatta dal progettista, con un solo valutatore, sul codice dell'applicazione e non su una sessione in esecuzione né su un dispositivo: ho letto T1, T2 e T3 schermata per schermata e ho confrontato ogni correzione dichiarata con il codice. Nella colonna «Stato», «verificato» significa che la correzione è presente nel codice; non significa che sia stata provata su un tablet. Possono mancare problemi visibili solo in esecuzione (layout, ordine reale del focus, uso con lettore di schermo). Le euristiche sono le dieci di Nielsen (1994) e la gravità segue la scala 0--4. Va ripetuta da 2--3 valutatori esterni prima o durante il pilota (Nielsen e Landauer, 1993, per l'effetto del numero di valutatori).

ID	Problema	Stato	Gravità residua
P-1	T3 non realizzato: «Capire un avviso» e «Organizzare una gita» mostrano solo un messaggio temporaneo	Corretto (verificato): T3 è nel prototipo (Descrivi l'avviso, Risposta, Sedia accanto, Vista di Marta); «Organizzare una gita» mostra «Non disponibile in questa versione»; tolti il messaggio «attività iniziata» e «Riprendi da…»	0
P-2	«Altra parola» duplicava la frase nella dettatura	Corretto	0
P-3	La chiusura riconosceva solo due frasi esatte	Corretto in parte (verificato): la chiusura confronta la frase intera, senza sottostringhe, e con «?» la conversazione resta aperta; «Riapri la conversazione» la riapre. L'elenco comprende «grazie», «grazie mille», «grazie, ho finito», «basta così», «basta grazie», «ho finito», «è tutto», «a posto così», «va bene così», «va bene, grazie», «ok grazie», «niente altro grazie», «non mi serve altro», «può/puoi chiudere», «chiudi». È un elenco chiuso: varianti come «ho finito, grazie» o «grazie, può chiudere» non chiudono	1
P-4	«Annulla» con due significati nel flusso «Dimentica»	Corretto: «No, la tengo» e «Ripristina la voce»	0
P-5	Sigle in minuscolo (PEC, ASL, INPS)	Corretto	0
P-6	Strumenti dell'osservatore non utilizzabili su tablet	Corretto in parte (verificato): il logo porta alla Home e non c'è più il conteggio dei tocchi; il pannello si apre con ?osservatore=1 (e con Ctrl+Alt+O da tastiera) e ora ha il pulsante «Chiudi pannello», che non azzera il registro. Aperto resta l'ingombro: aperto, il pannello copre l'angolo in basso a destra	1 (procedura al punto 8)
P-7	Livelli «Ti suggerisco» e «Scrivo io» portavano fuori dal percorso	Corretto: mostrano «Non disponibile in questa versione»	0
P-8	Bozze degli altri modelli senza le risposte date	Corretto	0

ID	Problema	Stato	Gravità residua
P-9	«Ciao, Lea»; titolo con la parola sbagliata; duplicati in Taccuino	Corretto (verificato): il salvataggio ripetuto aggiorna la scheda con lo stesso identificativo; una conversazione riaperta e richiusa non si duplica	0
P-10	Barra del livello sonoro statica	Corretto in parte (verificato): la barra si anima durante l'ascolto e l'animazione si ferma con la preferenza di sistema per la riduzione del movimento; non segue il livello reale del microfono, che nel test è simulato (H-07)	1
P-11	T2, chiusura: il riconoscimento cerca le parole come sottostringhe, per cui «abbastanza» (contiene «basta») o «grazie» dentro una frase senza «?» chiudono la conversazione. H5	Corretto (verificato): la chiusura confronta la frase intera e non cerca più sottostringhe: «abbastanza» o «grazie» dentro una frase non chiudono	0
P-12	T1, Bozza: le modifiche manuali al testo si perdono quando si apre «Non è quello che volevo» o si tocca «Annulla», perché il campo si ricrea a ogni cambio di stato. H3, H5	Corretto (verificato): il campo della bozza è controllato da uno stato; le modifiche restano aprendo il feedback o premendo «Annulla», e la versione precedente è conservata per «Torna alla versione precedente»	0
P-13	T1, bozza più corta: il testo generato dice «chiedo disdire un servizio» e, per gli altri modelli, frasi analoghe. H2, H4	Corretto (verificato): «chiedo di disdire il servizio», «chiedo di ricevere informazioni dall'ufficio», «chiedo di ottenere un rimborso o una risposta al reclamo»; nessun «chiedo chiedere»	0
P-14	T1, Salva la bozza: i segnaposto «[DA COMPLETARE: …]» sono fuori dal testo salvato, quindi la bozza nel Taccuino sembra completa anche se mancano dati. H1, H5	Corretto (verificato): i segnaposto «[DA COMPLETARE: ...]» sono aggiunti al testo modificabile, quindi anche al testo salvato nel Taccuino e alla versione riscritta	0
P-15	T1, domande: «Non so» passa subito alla domanda successiva o al riepilogo, mentre le altre risposte richiedono «Avanti», e la scelta non si vede. H4, H5	Corretto (verificato): «Non so» resta selezionato con un segno di spunta e non avanza; per procedere serve «Avanti»	0

ID	Problema	Stato	Gravità residua
P-16	T1, data precisa: tornando alla domanda il campo appare vuoto anche se il valore è salvato, e accetta qualsiasi testo. H1, H5	Corretto (verificato): il valore resta tornando alla domanda; accetta «5 dicembre 2026» e «05/12/2026»; con una data non valida compare un messaggio e «Avanti» resta disabilitato	0
P-17	T2, risposta: il segnaposto «Per esempio: grazie, basta così» suggerisce la frase di chiusura, e «Parla» la inserisce sempre; la misura di US06 ne è falsata. H6	Corretto (verificato): il segnaposto è neutro e la frase suggerita è stata tolta; «Parla» mostra l'ascolto e, con «Fine», non inserisce né invia nulla: compare «Il microfono è simulato: scrivi la risposta nel campo» e il focus va al campo	0
P-18	Logo: sembra un collegamento ma non porta alla Home; i tocchi si accumulano senza azzerarsi e il quinto apre gli strumenti dell'osservatore. H3, H4	Corretto (verificato): il logo riporta sempre alla Home e il conteggio dei tocchi non esiste più	0
P-19	Impostazioni: la nota «Le istruzioni restano sempre disponibili» promette un aiuto che non esiste. H2, H10	Corretto (verificato): la nota sulle istruzioni sempre disponibili non c'è più	0
P-20	Controlli doppi: «Dillo di nuovo» e «Parla» fanno la stessa cosa in T2, e «Scrivi» sposta solo il cursore su un campo già visibile in T1. H4, H8	Corretto (verificato): in T2 i pulsanti non sono più duplicati e in T1 il pulsante «Scrivi» è stato tolto; restano il campo visibile e «Parla»	0
P-21	Impostazioni: il pannello è modale ma Tab può uscirne, e il gruppo della dimensione del testo non ha il ruolo di gruppo (WCAG 2.2, criterio 2.4.3)	Corretto (verificato): focus contenuto nel pannello, Tab circolare, chiusura con Esc; i selettori di dimensione del testo e di contrasto hanno role="group" e sono associati al loro titolo	0
P-22	T1, Riepilogo e Bozza: «Cambia la richiesta» (porta alla prima domanda) e «Torna alle domande» (all'ultima vista) sono quasi equivalenti; nella Bozza il primo compare solo nello stato iniziale o dopo due tentativi. H4, H7	Corretto (verificato): nel riepilogo di un modello c'è solo «Rivedi le risposte»; nella Bozza «Cambia la richiesta» compare nello stato iniziale oppure, dopo due tentativi, nel riquadro, mai insieme	0
P-23	Taccuino: bozze e conversazioni	Corretto in parte (verificato): stato vuoto	1

ID	Problema	Stato	Gravità residua
	non si possono riaprire né cancellare; il testo parla di «attività» che non compaiono; i titoli hanno livelli incoerenti. H2, H4, H6	esplicativo, intestazioni coerenti (h1, h2, h3), ritorno alla Home dal Taccuino. Bozze e conversazioni restano non riapribili né cancellabili	
P-24	T3, Sedia accanto, conferma: dopo «Smetti di condividere» e «Conferma» il titolo diventa «Condivisione interrotta», ma il riquadro «Cosa vede Marta» continua a elencare ciò che Marta vede. H1, H5; H-14	Aperto (verificato): il riquadro non dipende dallo stato della condivisione e dopo la revoca dice il contrario di ciò che accade. Altera US11	3
P-25	T3, «Smetti di condividere»: la richiesta di conferma compare in fondo alla schermata, sotto i pulsanti, e il focus non si sposta; a 150% e 200% può restare fuori vista e il pulsante sembra non fare nulla. H1, H7	Aperto (verificato): il riquadro «Vuoi smettere di condividere?» è in coda alla schermata e non riceve il focus; da provare a 150–200%. Può allungare il tempo di revoca di US11	2
P-26	T3, suggerimento di Marta: «Usa» e «Non ora» cancellano anche il messaggio di Marta dalla cronologia, che perde così l'autore «Marta». H1, H6	Aperto (verificato): la cronologia legge lo stesso stato della scheda, che «Usa» e «Non ora» azzerano; i tre autori compaiono insieme solo finché la scheda è aperta	2
P-27	T3, Risposta: i due pulsanti «Apri» hanno la stessa etichetta, senza il nome della fonte (per un lettore di schermo e nel registro non si distinguono); «Copia» ha l'icona di una matita. H2, H4	Aperto (verificato): etichetta accessibile e voce di registro identiche per le due fonti; l'icona di «Copia» è la matita	1
P-28	T3, Sedia accanto: «Tutta la cronologia» promette «le attività precedenti presenti nel Taccuino», ma nella cronologia compaiono solo le conversazioni salvate e non le bozze. H2	Aperto (verificato): l'elenco mostra le conversazioni e non le bozze	1

Punti di forza confermati. Nulla parte senza conferma; la richiesta resta visibile e modificabile; «Da decidere» non obbliga a rispondere; «Dimentica» chiede conferma e offre «Ripristina la voce»; l'avviso

«Chiaro non invia nulla» compare nelle schermate in cui può nascere l'equivoco; il focus va al titolo a ogni cambio di schermata; Esc chiude le Impostazioni; i pulsanti disabilitati mantengono il contrasto. In T3 l'ordine delle quattro sezioni è fisso e «Cosa non so» segue «In breve» in una riga corta; «Cosa vede Marta» e «Smetti di condividere» sono sempre presenti; la cronologia distingue gli autori con nome e icona; la vista di Marta è in sola lettura e dichiara di non controllare il tablet.

Effetto sulle misure. P-12, P-14, P-15, P-17 e P-18 non alterano più le misure: la modifica manuale della bozza si conserva, un segnaposto rimasto è visibile nel testo salvato (conta come elemento mancante, sezione 7), il logo non apre gli strumenti dell'osservatore e la frase di chiusura non è suggerita, quindi US06 misura ciò che il partecipante scrive da sé. Resta un limite: la chiusura riconosce un elenco chiuso di frasi (P-3), e una chiusura naturale fuori elenco conta come non gestita, che è proprio ciò che US06 deve rilevare. In T3, P-24 falsa US11 dopo la revoca (il riquadro dice che Marta vede ancora la conversazione) e P-25 può allungare il tempo di revoca; P-26 non altera le misure ma toglie Marta dalla cronologia. Per US09 il registro mostra solo i tocchi su «Apri»: «Che cosa ho usato» è sempre visibile e non si tocca, quindi la sua consultazione la annota l'osservatore.

Da provare prima del pilota. P-24 e P-25 alterano US11 e vanno corretti prima del pilota. I problemi rimasti (P-3, P-6, P-10, P-23, P-26, P-27, P-28) si rivalutano dopo il pilota; in particolare, nel pilota si annotano le frasi di chiusura non riconosciute, per decidere se ampliare l'elenco (modifica da registrare nella tabella della sezione 10). Le correzioni, verificate nel codice ma non provate su un dispositivo, vanno comunque provate sul tablet con un percorso fisso: T1 con modifica manuale della bozza, «Non è quello che volevo», «Annulla» e salvataggio con un segnaposto; T2 con le chiusure della scheda e, come controllo, «abbastanza» e «grazie, quando apre la domenica» senza «?». Le correzioni non cambiano le soglie della sezione 3, ma ogni modifica al prototipo dopo il congelamento si annota con la data (sezione 10). Percorso fisso di T3: descrizione dell'avviso con «Parla» e «Fine», apertura di entrambe le fonti, invito con i tre metodi, scelta dell'ambito, passaggio alla vista di Marta e ritorno con un suggerimento, «Usa» e «Non ora», revoca con «Conferma» e «Annulla», salvataggio nel Taccuino.

Limiti noti che non sono difetti del prototipo ma della simulazione. L'errore di trascrizione è sempre segnalato con «?», quindi gli errori non segnalati (H-09) non si possono osservare. Nella risposta finale di T2 «Parla» mostra l'ascolto ma non inserisce testo: il partecipante scrive la frase di chiusura, così US06 misura le frasi che usa da sé. La barra del livello sonoro si anima durante l'ascolto ma non segue la voce, perché il microfono è simulato. In T3 la risposta è fissa e non dipende dal testo scritto, «Fine» nella descrizione inserisce sempre la stessa frase, link, QR e codice sono simulati e Marta è l'osservatore sullo stesso tablet; i tocchi dell'osservatore nella vista di Marta finiscono nel registro e si annotano sulla scheda.

Tabella di raccordo con il Design. La tabella ricollega i problemi del Design (H-xx dal brief dei frame, F4-x e A-x dai frame di Figma Make) ai problemi P-xx del prototipo finale. Dove manca un P corrispondente il problema non è tracciato in questo registro e va riverificato nel pilota. L'esito è quello dichiarato in questa sezione, verificato nel codice e non su un dispositivo.

ID Design	Problema	Gravità iniziale	P corrispondente	Esito

ID Design	Problema	Gravità iniziale	P corrispondente	Esito
H-01	Scheda sotto la domanda su tablet verticale (T1, F3)	3	—	Non tracciato. Scheda ripiegabile nel flusso; verifica a 150–200% sul tablet ancora da fare (Design, 9.3)
H-02	Risposte pronte scelte senza leggere (T1, F3)	2	P-15 (in parte)	P-15 corretto: «Non so» resta selezionato e non avanza. L'ordine variabile non è verificato
H-03	«Va bene» sulla bozza fa credere che la lettera sia inviata (T1, F5)	3	—	Confermato tra i punti di forza: «Salva la bozza» e l'avviso «Chiaro non invia nulla»
H-04	«Cambia» e «Non è quello che volevo» equivalenti (T1, F4–F5)	2	P-22	Corretto
H-05	«Scrivo io» poco scopribile (T1, F1)	2	P-7 (in parte)	P-7 corretto: i livelli non attivi mostrano «Non disponibile in questa versione»
H-06	Nessuna guida per il tutor	2	—	Non coperta (sezione 10)
H-07	Stato di ascolto distinto solo dal colore (T2, F6)	3	P-10, P-17	Corretto in parte: gravità residua 1 (la barra non segue il microfono simulato)
H-08	Parole incerte con sottolineatura debole (T2, F6)	2	—	Non tracciato; il contrasto è verificato per ispezione (US15)
H-09	Errori di trascrizione non segnalati (T2, F6)	3	—	Non osservabile: nel test l'errore è sempre segnalato con «?»
H-10	«Grazie» a metà conversazione la chiude (T2, F6)	3	P-3, P-11	P-11 corretto; P-3 corretto in parte, gravità 1 (elenco chiuso di frasi)
H-11	«Cosa ricordo» non si scopre (T2, F8)	2	— (P-23 per il Taccuino)	Nessun P diretto; P-23 corretto in parte, gravità 1
H-12	«Dimentica» agisce subito (T2, F8)	2	P-4	Corretto: «No, la tengo» e «Ripristina la voce»

ID Design	Problema	Gravità iniziale	P corrispondente	Esito
H-13	Risposta lunga, «Cosa non so» può restare fuori vista (T3, F7)	3	---	Corretto nel progetto: «Cosa non so» segue «In breve» in una riga corta; la schermata resta lunga e va provata a 150–200%
H-14	Rosa non vede che cosa vede Marta (T3, F9)	3	P-24	Riquadro «Cosa vede Marta» sempre visibile, ma dopo la revoca dice il falso: aperto, gravità 3
H-15	Codice da digitare soggetto a errori (T3, F9)	2	P-27 (solo «Copia»)	Corretto: link e QR prima, codice come ripiego in grande con «Copia»; l'icona di «Copia» è la matita (P-27)
H-16	«Su cosa mi baso» inteso come spiegazione del perché (T3, F7)	2	---	Corretto: «Che cosa ho usato», con la riga «non spiega come ragiona il modello»
F4-1…F4-7	Frase finale e controlli di F4	3, 3, 2, 2, 1, 2, 1	P-13, P-22	F4-4 e F4-5 unificati in «Rivedi le risposte» (P-22); testi della bozza in P-13; gli altri non sono tracciati
A-1…A-4	Percorso «Un altro tipo di lettera» (da F2)	3, 2, 2, 2	P-17 (solo «Parla»)	Non tracciati come P: da riprovare sul percorso

Problemi nuovi e problemi già nel Design. P-2, P-12, P-14, P-16, P-19, P-20, P-21 e P-24…P-28 sono problemi nuovi, emersi dall'ispezione del codice e senza corrispondente nel Design. P-4, P-5, P-6, P-8, P-9 e P-18 sono già riflessi nel Design (9.5). I problemi W-1…W-13 del cognitive walkthrough sono collegati ai P-xx nell'Allegato A del Design.

Verifica dell'accessibilità (US15). Fatta per ispezione del codice e per calcolo dei rapporti di contrasto (WCAG 2.2, criterio 1.4.3; W3C, 2023), non misurata su un dispositivo. Il contrasto del focus dei campi di testo, aggiunto dopo la verifica precedente, non è stato rimisurato.

Coppia colori	Tema chiaro	Tema scuro
Testo su sfondo	15,7 : 1	18,4 : 1
Testo secondario su sfondo o superficie	da 9,3 a 10,3 : 1	13,5 : 1
Testo secondario su superficie attenuata (caso peggiore)	8,3 : 1	10,8 : 1
Testo su pulsante pieno	11,4 : 1	12,4 : 1

Coppia colori	Tema chiaro	Tema scuro
Bordi dei controlli (non testo, minimo 3 : 1)	da 4,4 a 4,9 : 1	9,2 : 1

Tutti i testi superano 7 : 1. Il corpo del testo è di 20 px e i pulsanti di 22 px; i bersagli hanno altezza minima di 48–56 px con distanza di almeno 8 px; non ci sono timer, gesti obbligatori né funzioni solo al passaggio del mouse (l'osservatore si apre con un indirizzo o con una combinazione di tasti, non con un gesto sullo schermo). Il testo si ingrandisce al 150% e al 200%. Gli elementi di T3 usano le stesse classi dei pulsanti (altezza minima 56 px); le scelte di invito e di ambito sono alte almeno 88 px, il codice di ripiego è scritto a 2 em e il testo più piccolo delle nuove schermate è di circa 20 px. I colori fissi del QR e delle icone degli autori hanno un rapporto di circa 17,9 : 1 e 10,0 : 1.

3. Specifiche di usabilità e task selezionati

Delle sedici specifiche del documento di Design, quindici sono verificabili: tredici su T1 e T2, e US09 e US11 su T3 (solo su Chiaro); US16 resta fuori. Poiché non c'è un gruppo di progettisti con cui concordarle, i valori sono fissati da me e congelati con data prima della prima sessione; dopo il pilota si possono ricalibrare una sola volta, annotando il motivo (sezione 10). Il formato è quello di Whiteside, Bennett e Holtzblatt (1988) ripreso da Rosson e Carroll (2002): attributo, misura, livello minimo accettabile (worst) e obiettivo (planned); il terzo livello, best, si fissa nella sezione 10.

ID	Misura	Task	Strumento	Minimo	Obiettivo
US01	Completezza della prima richiesta: quota degli elementi attesi presenti (quattro per T1, sezione 8)	T1	Griglia, due codificatori	70%	90%
US02	Tempo dall'avvio al primo invio	T1	Cronometro dell'osservatore e registro	240 s	180 s
US03	Invii all'assistente per task completato (indicatore indiretto del consumo di calcolo)	T1	Registro	2,0	1,5
US04	Quota di partecipanti che completa il task con al più un intervento dell'osservatore	T1, T2	Scheda dell'osservatore	80%	90%
US05	Partecipanti che inviano con l'errore di trascrizione segnalato non corretto	T2	Scheda dell'osservatore	0 casi su N*	0 casi
US06	Frasi di chiusura naturali gestite come l'utente intende; chiusure involontarie al massimo 5%	T2	Registro e scheda	90%	95%
US07	«Non è quello che volevo» seguito da	T1	Registro	40%	60%

ID	Misura	Task	Strumento	Minimo	Obiettivo
	un esito accettato entro due tentativi				
US08	Partecipanti che, a fine task, indicano una cosa che l'assistente non ha verificato	T1, T2	Domanda finale, codifica	70%	85%
US09	Verifica della risposta: partecipanti che, invitati a controllarla, aprono una fonte o consultano «Che cosa ho usato» entro 30 s dalla comparsa della risposta	T3	Registro («Apri»), osservatore («Che cosa ho usato»), cronometro	80%*	90%
US10	Partecipanti che trovano e cancellano una voce di memoria entro 60 s	T2	Cronometro	90%*	95%
US11	Condivisione: partecipanti che, dopo l'invito, dicono che cosa vede Marta e revocano la condivisione entro 30 s dalla richiesta	T3	Domanda dell'osservatore, registro («Smetti di condividere», «Conferma»), cronometro	80%*	90%
US12	Interventi dell'osservatore per task	T1, T2	Scheda	1	0,5
US13	Carico percepito: NASA-TLX raw (Hart e Staveland, 1988)	T1, T2	Questionario	non peggiore della chat	almeno 20% più basso
US14	Soddisfazione: SUS (Brooke, 1996)	tutti	Questionario	68	80
US15	Accessibilità: testi di almeno 20 px, contrasto 7 : 1, bersagli di almeno 48 px, nessun timer	tutti	Ispezione (sezione 2)	100%	100%

*Con 8 partecipanti ogni caso vale 12,5 punti percentuali: US05 equivale a zero casi e US10 al 90% richiede 8 su 8 (7 su 8 è 87,5%). Con meno partecipanti si applica la stessa regola. US09 e US11 all'80% richiedono 7 su 8 (6 su 8 è 75%).

Modifiche rispetto al documento di Design. US03, US12 e US13 non hanno più una condizione di base interna a Chiaro: la confrontano con la chat libera nelle ipotesi (sezione 6) e hanno soglie assolute qui. US05 è riformulata come numero di casi. US09 e US11 si misurano solo su T3 e solo in Chiaro, senza confronto con la chat (che non ha la Sedia accanto), con le soglie del Design; US04 e US12 si calcolano su T1 e T2 per il confronto e su T3 si riportano a parte.

Task selezionati. T1, T2 e T3: i primi due coprono i claim C1–C9 e C10–C18, T3 i claim C19–C27 (verifica delle fonti e condivisione). I problemi euristici verificabili sono H-01…H-05 e H-07…H-16 (H-09 solo per gli errori segnalati); H-06 (guida per il tutor) non lo è. I problemi W-1…W-13 del cognitive walkthrough (Design, Allegato A) riguardano T1, T2 e T3 e sono collegati a H-xx, specifiche e P-xx nell'allegato stesso.

Specifiche escluse. US16 (fiducia calibrata) richiede un task con una risposta volutamente non verificabile o errata e un debriefing. La risposta di T3 è corretta e coerente con le fonti, quindi la specifica, opzionale nel Design, non è verificabile in questa versione.

4. Obiettivi e disegno dello studio

Lo studio è comparativo e within-group: ogni partecipante usa sia Chiaro sia una chat libera, con ordine e varianti bilanciati su otto combinazioni. T3 è un blocco aggiuntivo solo su Chiaro, senza confronto.

Obiettivi della valutazione sommativa

- Validare Chiaro su T1, T2 e T3 rispetto alle specifiche US01–US15 della sezione 3.
- Rigettare le ipotesi nulle della sezione 6, con la completezza della prima richiesta (US01) come ipotesi primaria.
- Mostrare un grado sufficiente di soddisfazione: SUS di almeno 68, la media di riferimento (Sauro e Lewis, 2016).

Condizione di confronto. Una chat con un modello linguistico di uso comune, aperta su una pagina vuota, sullo stesso tablet e con lo stesso testo ingrandito scelto dal partecipante. Non ha scaffolding: nessun modello, nessuna mini-intervista, nessuna scheda della richiesta. La dettatura è quella della tastiera del tablet. Ne derivano due asimmetrie da dichiarare: il microfono della chat è reale e quello di Chiaro è simulato, e l'assistente della chat risponde davvero mentre quello di Chiaro è scritto a priori. T3 non ha condizione di confronto: la chat libera non ha un equivalente della Sedia accanto.

Fattori. Variabile indipendente: interfaccia (Chiaro, chat libera). Fattori di controllo, bilanciati e non analizzati separatamente: ordine dei blocchi, variante di T1 su Chiaro, ordine dei task nel blocco.

Bilanciamento e limitazione dei learning bias. Otto combinazioni, una per partecipante. T1 ha due varianti con contenuto diverso (A: palestra, B: telefono e internet), così chi usa la seconda interfaccia non ripete lo stesso compito. T2 ha la stessa frase nelle due condizioni, perché il prototipo accetta una sola frase: l'effetto di pratica colpisce in modo simmetrico chi usa Chiaro per primo e chi la usa per secondo.

Partecipante	Primo blocco	T1 su Chiaro	Ordine dei task nel blocco
P1	Chiaro	A	T1 poi T2
P2	Chiaro	A	T2 poi T1
P3	Chiaro	B	T1 poi T2
P4	Chiaro	B	T2 poi T1
P5	Chat	A	T1 poi T2

Partecipante	Primo blocco	T1 su Chiaro	Ordine dei task nel blocco
P6	Chat	A	T2 poi T1
P7	Chat	B	T1 poi T2
P8	Chat	B	T2 poi T1

La variante di T1 non usata su Chiaro è quella della chat. Altre misure contro il bias di apprendimento: un compito di riscaldamento senza relazione con T1 e T2 (cambiare la dimensione del testo nelle impostazioni del tablet), una pausa di 5–10 minuti tra i blocchi e nessun feedback sul rendimento durante la sessione. Con meno di otto partecipanti si tolgono le combinazioni mantenendo i due ordini dei blocchi in pari numero. T3 si svolge sempre per ultimo, in un blocco solo su Chiaro, per non alterare il confronto: SUS e NASA-TLX si compilano prima di T3, così Chiaro e la chat sono valutati dopo lo stesso numero di task (due). L'ordine di T3 non è bilanciato e il suo effetto di fatica non è controllato.

Sessione. Circa 75 minuti: accoglienza e consenso (5), questionario di background (5), riscaldamento (3), blocco 1 con questionario di reazione (20), pausa (5), blocco 2 con questionario (20), blocco 3 solo su Chiaro con T3 (10), confronto finale e domande aperte (5). La durata massima di un task è 10 minuti; oltre, l'osservatore lo interrompe e lo registra come non completato. Il limite è una regola dello studio e non un timer mostrato al partecipante.

5. Partecipanti e questionari

L'obiettivo sono otto partecipanti di 60 anni o più, più tre per il pilota, scelti da un campione di 12–15 persone che compilano prima il questionario di background. Con sei partecipanti si può ancora rigettare un'ipotesi con il test della sezione 6; con cinque o meno no.

Criteri. Inclusione: almeno 60 anni; italiano fluente; uso almeno occasionale di smartphone o tablet; consenso informato. Esclusione: diagnosi di demenza o di grave deficit visivo o uditivo non corretto (autodichiarazione); aver partecipato alla costruzione del prototipo. Selezione per quote, con almeno due persone di 80 anni o più se possibile, perché l'usabilità cala in quella fascia (E32), e con un misto di esperienza con chatbot (mai usato, provato, uso almeno mensile). Se non si trovano partecipanti della fascia di età, si può fare il pilota con adulti più giovani, dichiarandoli un campione di ripiego: i risultati non valgono per la popolazione target.

Etica e dati. Consenso scritto e possibilità di ritirarsi. Codici anonimi (P1, P2…). Nei task si usano dati inventati e si dice ai partecipanti di non scrivere dati personali reali (E39, E40). Le registrazioni, se si fanno con consenso, si cancellano dopo la codifica.

Questionario di background (prima delle sessioni)

N.	Domanda	Risposta
B1	Fascia di età	60–69, 70–79, 80 o più
B2	Titolo di studio	scelta tra livelli
B3	Dispositivi che usa (smartphone, tablet, computer)	scelta multipla

N.	Domanda	Risposta
B4	Frequenza d'uso di smartphone o tablet	mai, mensile, settimanale, ogni giorno
B5	Operazioni che fa da solo/a (chiamate, messaggi, e-mail, banca online, servizi pubblici online)	scelta multipla
B6	Uso di assistenti vocali (Alexa, Siri, Google)	mai, provato, mensile, settimanale
B7	Uso di chatbot o assistenti basati su modelli linguistici	mai, provato, mensile, settimanale
B8	Chi la aiuta con le cose digitali	nessuno, familiari, altri
B9	Quanto legge facilmente il testo piccolo sullo schermo	1–5
B10	Difficoltà a toccare con precisione (tremore, dita)	1–5
B11	Difficoltà a sentire o farsi capire dal microfono	1–5
B12	Dimensione del testo che usa di solito	normale, grande, molto grande
B13	Quante volte ha scritto una lettera formale (disdetta, reclamo) negli ultimi 12 mesi	mai, 1–2, 3 o più
B14	Ha familiarità con moduli precompilati o con il ricettario di cucina (verifica della metafora M2)	1–5
B15	Dove e in che posizione usa di solito tablet o smartphone (tavolo, divano o poltrona, a letto, fuori casa; apparecchio appoggiato o tenuto in mano)	scelta multipla

Questionario di reazione (dopo ciascuna condizione)

- **SUS** (Brooke, 1996), dieci affermazioni a cinque gradi. Le formulazioni italiane sono una mia traduzione provvisoria da confrontare con una versione italiana validata prima dell'uso. Punteggio da 0 a 100 con la formula standard.
- **NASA-TLX nella versione raw** (Hart e Staveland, 1988): esigenza mentale, fisica, temporale, prestazione, impegno e frustrazione, ciascuna su una scala da 0 a 100; punteggio = media delle sei.
- **Domande aggiuntive a cinque gradi (da «per niente» a «molto»):** R1 «Ho capito che cosa stava facendo l'assistente»; R2 «Sono sicuro/a che la mia richiesta fosse completa»; R3 «Mi sono sentito/a in controllo».
- **Domanda di comprensione dei limiti (US08):** «Ci è qualcosa che l'assistente non ha controllato o non può sapere? Se sì, che cosa?», a risposta aperta.
- **Alla fine:** quale delle due interfacce preferisce (scelta forzata, chiesta alla fine del blocco 2 e prima di T3), perché, e che cosa cambierebbe in Chiaro.
- **Dopo T3:** le domande R1–R3 e la domanda aperta «Come ha deciso se fidarsi della risposta?»; sulla scheda si annota anche che cosa il partecipante dice che Marta poteva vedere.

6. Variabili, ipotesi nulle e test

L'ipotesi primaria riguarda la completezza della prima richiesta in T1; le altre sei sono secondarie: cinque confronti tra condizioni (H0-2…H0-6) e il confronto del SUS di Chiaro con la soglia di 68 (H0-7). Ogni partecipante contribuisce con una coppia di valori (Chiaro, chat), quindi il test è a coppie.

ID	Ipotesi nulla	Variabile dipendente	Specifica	Ruolo
H0-1	La mediana della completezza della prima richiesta in T1 non differisce tra Chiaro e chat	Quota di elementi presenti	US01	Primaria
H0-2	Il tempo al primo invio in T1 non differisce	Secondi	US02	Secondaria
H0-3	Il numero di invii per task completato in T1 non differisce	Invii	US03	Secondaria
H0-4	Gli interventi dell'osservatore per task non differiscono	Conteggio medio su T1 e T2	US12	Secondaria
H0-5	Il NASA-TLX raw non differisce	Punteggio 0–100	US13	Secondaria
H0-6	Il SUS non differisce	Punteggio 0–100	US14	Secondaria
H0-7	La mediana del SUS di Chiaro non supera 68	Punteggio 0–100	US14	Soddisfazione

US05, US06, US07, US08, US09, US10 e US11 riguardano comportamenti che esistono solo in Chiaro e si confrontano con la soglia di minimo e di obiettivo, senza test.

Cornice ISO/IEC 9126. Le variabili dipendenti sono lette con il modello di qualità ISO/IEC 9126-1 (2001). Per l'usabilità il modello distingue comprensibilità, apprendibilità, operabilità e attrattiva; per la qualità in uso aggiunge efficacia, produttività, sicurezza e soddisfazione. Si selezionano le sotto-caratteristiche che una sessione singola permette di osservare: comprensibilità, operabilità, attrattiva e, come misura di efficienza, il tempo. L'apprendibilità resta fuori, perché la sessione non osserva l'uso ripetuto (sezione 1, limite 4). L'accuratezza e il tempo non appartengono all'usabilità in senso stretto (nello standard sono funzionalità ed efficienza): si tengono perché la traccia le richiede. US05, US06, US07, US08, US09, US10 e US11 ricadono in operabilità e comprensibilità. La mappatura è una scelta del progettista e non discende dallo standard.

Ipotesi	Variabile	Sotto-criterio ISO/IEC 9126
H0-1	Completezza della prima richiesta (US01)	Accuratezza: la prima richiesta contiene i quattro elementi attesi della griglia
H0-2	Tempo al primo invio (US02)	Tempo (efficienza)

Ipotesi	Variabile	Sotto-criterio ISO/IEC 9126
H0-3	Invii per task completato (US03)	Utilizzo di risorse (efficienza), come indicatore indiretto del consumo di calcolo
H0-4	Interventi dell'osservatore (US12)	Operabilità: il compito si porta a termine senza aiuto
H0-5	NASA-TLX raw (US13)	Comprensibilità e operabilità: sforzo richiesto per capire e usare
H0-6	SUS (US14)	Attrattiva e comprensibilità
H0-7	SUS di Chiaro rispetto a 68 (US14)	Attrattiva (soddisfazione, nella qualità in uso)

Test. Per H0-1…H0-6, test dei ranghi con segno di Wilcoxon (1945) per dati appaiati, bilaterale, $\alpha = 0{,}05$, valore p esatto. Per H0-7, lo stesso test a un campione rispetto a 68. La scelta non parametrica dipende dal campione piccolo e da misure ordinali o asimmetriche (tempi, punteggi).

Potenza. Con N coppie senza pareggi il p bilaterale minimo è 2 / 2^N: 0,0078 con N = 8, 0,031 con N = 6, 0,0625 con N = 5. Con meno di sei partecipanti con dati validi nessuna ipotesi nulla può essere rigettata, per costruzione.

Confronti multipli. H0-1 è l'unica ipotesi confermativa, con $\alpha = 0{,}05$. Per H0-2…H0-6 si riportano p non corretti e p corretti con Holm (1979); con otto partecipanti la correzione per cinque test richiede $p \leq 0{,}01$ per il più piccolo, e il minimo possibile è 0,0078. Questi cinque test sono dichiarati esplorativi se $N < 8$.

Dimensione dell'effetto. Mediane e scarto interquartile per ciascuna condizione, più la correlazione per ranghi di coppie (Kerby, 2014). Il mancato rigetto di un'ipotesi nulla non dimostra l'equivalenza.

Dati mancanti. Se un partecipante non completa un task, il suo tempo è censurato a 10 minuti (il tetto della sezione 4) e il caso è segnalato; la coppia resta nell'analisi.

7. Istruzioni e task

Le istruzioni generali si leggono a voce, identiche per tutti. Le schede dei task descrivono lo scopo e non i passi da fare, come richiede la traccia.

Istruzioni generali (testo da leggere)

> *Grazie di essere qui. Stiamo provando un'applicazione: non stiamo valutando lei, e non ci sono risposte sbagliate. Se qualcosa non è chiaro, è un difetto dell'applicazione, non suo. Può fermarsi quando vuole. Le chiederò di pensare ad alta voce: ci dica che cosa guarda, che cosa si aspetta e che cosa non capisce. Io prenderò appunti e non potrò aiutarla, tranne se lei è bloccato/a. Useremo solo dati inventati: non scriva i suoi dati personali. Il microfono di questa applicazione è simulato: quando le chiederò di parlare, legga la frase scritta sulla scheda. In un'attività mi vedrà fare la parte di Marta, una persona che può aiutarla da casa: lo faccio io, sul tablet. Il tablet registra solo i tocchi, non la sua voce.*

Schede dei task

Task	Scheda consegnata al partecipante
T1-A	Lei è iscritto/a a una palestra e non ci va più. Vuole smettere di pagare dal mese prossimo e manderebbe la lettera con la raccomandata. Non le piacciono le lettere lunghe. Ottenga una lettera che le va bene e la conservi.
T1-B	Ha un contratto di telefono e internet che non le serve più. Vuole disdirlo da subito e lo farebbe con la PEC. Non le piacciono le lettere lunghe. Ottenga una lettera che le va bene e la conservi.
T2 (Chiaro)	Vuole sapere se l'ambulatorio del suo medico, il dottor Neri, è aperto il sabato. Faccia la domanda dicendo: «Quando apre al sabato l'ambulatorio del dottor Neri?». Quando ha avuto la risposta, concluda la conversazione. Non vuole che l'applicazione ricordi chi è il suo medico: faccia in modo che lo dimentichi.
T2 (chat)	Come T2 (Chiaro), senza l'ultima frase sulla memoria.
T3 (Chiaro)	Parte A: ha ricevuto un avviso di pagamento del Comune di Valle Serena: 86,40 euro da pagare entro il 30 novembre 2026. Lo descriva all'applicazione dicendo: «Ho ricevuto un avviso di pagamento dal Comune di Valle Serena: devo pagare 86,40 euro entro il 30 novembre 2026.» Vuole capire che cosa deve fare e controllare se può fidarsi della risposta. Poi vuole farsi aiutare da sua figlia Marta, ma solo su questa conversazione. Parte B (consegnata dopo il suggerimento di Marta): Marta ha finito di aiutarla e lei non vuole più che veda la conversazione. Faccia in modo che non possa più vederla e conservi la conversazione.

Nelle schede di T1 la lettera breve è un obiettivo che il partecipante deve raggiungere da sé: la prima bozza di Chiaro non lo rispetta, quindi US07 si osserva senza che la scheda spieghi come chiedere una modifica. In T2 la scheda non dice di controllare la trascrizione, perché US05 misura se il partecipante la rilegge di sua iniziativa. Nella scheda di T3 si dice di controllare la risposta ma non come: US09 misura se il partecipante apre una fonte o consulta «Che cosa ho usato» di sua iniziativa. Il suggerimento di Marta è sempre lo stesso («Controlla il numero dell'avviso con quello sul foglio») e lo scrive l'osservatore.

Criteri di successo

- **T1:** una bozza salvata (in Chiaro nel Taccuino, nella chat copiata in una nota) che nomina il servizio, la data di effetto e il modo di spedizione, e che il partecipante giudica breve. Un segnaposto «[DA COMPLETARE: ...]» rimasto nel testo salvato vale come elemento mancante.
- **T2:** la risposta è stata ottenuta, la conversazione è chiusa e, in Chiaro, la voce di memoria è stata cancellata.
- **T3:** la risposta all'avviso è stata ottenuta, l'invito è stato fatto con uno dei tre metodi e con un ambito scelto, la condivisione è stata revocata con «Conferma» e la conversazione è salvata nel Taccuino.
- **Abbandono:** il partecipante lo dichiara oppure scadono i 10 minuti.

Politica degli interventi dell'osservatore. L0: nessun intervento. L1: sollecito neutro («Cosa sta pensando?», «Cosa si aspettava?»), non conta come intervento ai fini di US04 e US12. L2: suggerimento sul risultato da ottenere senza indicare il comando; conta come un intervento. L3: l'osservatore compie il passo; il task è registrato come non completato in autonomia. Nella vista di Marta (T3) l'osservatore agisce da copione: i suoi tocchi non sono interventi (L0) e sono annotati sulla scheda.

8. Raccolta dei dati

I partecipanti pensano ad alta voce mentre un osservatore annota. Interpreto il «collaborative think aloud» della traccia come un pensare ad alta voce in presenza dell'osservatore, che può fare solo i solleciti neutri della sezione 7. Se il partecipante lo desidera, può essere presente un familiare, come nello scenario 1 (Rosa con la tutor): in quel caso chi accompagna non tocca il tablet e la sua presenza è annotata.

Strumenti

- **Scheda dell'osservatore** (sotto), cartacea o su un secondo dispositivo, una per partecipante.
- **Registro dell'applicazione:** ogni tocco su un pulsante è registrato con data e ora e salvato nel browser. Il pannello dell'osservatore si apre aprendo l'indirizzo con ?osservatore=1 (o con Ctrl+Alt+O da tastiera; il logo «C» riporta sempre alla Home), e si chiude con «Chiudi pannello» (che non tocca il registro) oppure con «Cambia partecipante», che azzera anche il registro. Per T3 il registro riporta «Apri» senza il nome della fonte (P-27): quale fonte è stata aperta si annota sulla scheda.
- **Procedura per il pannello** (problema P-6): resta chiuso durante i task, perché copre l'angolo in basso a destra. Inizio e fine dei task si prendono con un cronometro separato e si scrivono sulla scheda. A fine sessione si aprono il pannello, si preme «Esporta registro» e solo dopo «Cambia partecipante». Il registro serve a contare i tocchi e gli invii; i tempi di riferimento sono quelli del cronometro.
- **Procedura per la vista di Marta (T3):** l'osservatore dice «Ora faccio la parte di Marta», tocca «Passa alla vista di Marta (simulata)», scrive il suggerimento di copione, lo invia, restituisce il tablet e consegna la parte B della scheda. I suoi tocchi sono nel registro e si annotano sulla scheda.
- **Registrazione dello schermo e dell'audio**, solo con consenso, per la codifica successiva.

Scheda dell'osservatore (una per task)

Campo	Contenuto
Intestazione	Codice partecipante, data, osservatore, condizione (Chiaro o chat), variante di T1, ordine dei task, dimensione del testo scelta
Tempi	Inizio, fine, durata (secondi), primo invio all'assistente (secondi dall'inizio)
Esito	Completato in autonomia, completato con intervento, non completato
Invii	Numero di invii all'assistente; numero di «Non è quello che

Campo	Contenuto
	volevo»; esito dopo ciascuno
Prima richiesta	Testo esatto della prima richiesta inviata (frase di «Ecco cosa chiederò» in Chiaro, primo messaggio nella chat)
Griglia US01 (T1)	Servizio; data di effetto; modo di spedizione; richiesta di brevità: presente 1 o assente 0 per ciascuno, e barriere osservate (prolissità, incompletezza, sovraspecificazione, sottospecificazione)
Solo T2	Errore di trascrizione corretto prima dell'invio (sì o no); frase di chiusura usata e se è stata capita; voce di memoria cancellata (sì o no) e secondi impiegati
Solo T3	Prima fonte aperta (sì o no; quale; secondi dalla comparsa della risposta); «Che cosa ho usato» consultato (sì o no, annotato dall'osservatore); metodo di invito e ambito scelti; risposta a «Che cosa può vedere Marta adesso?» (corretta, parziale, errata); secondi dalla parte B alla conferma di «Smetti di condividere»; suggerimento di Marta: «Usa» o «Non ora»
Interventi	Per ciascuno: ora, livello (L1, L2, L3), parole usate, motivo
Errori e difficoltà	Schermata, che cosa è successo, euristica violata (H1–H10), gravità 0–4
Citazioni	Frasi del partecipante, con l'ora
Domanda finale (US08)	Risposta alla domanda sui limiti, per la codifica successiva

Esempio compilato (T1 su Chiaro, partecipante e dati inventati). Serve solo a mostrare come si usa la scheda. Codici dell'esito: S = completato in autonomia; P = completato con intervento; F = non completato.

Campo	Esempio compilato
Intestazione	P3 · 10/12/2026 · osservatore: L. · Chiaro · T1-B (telefono e internet) · ordine: T1 poi T2 · testo al 150%
Tempi	Inizio 10:12:05 · fine 10:19:40 · durata 455 s · primo invio 188 s
Esito	P: completato con intervento (L2)
Invii	2 invii · 1 «Non è quello che volevo» (motivo scelto: «Troppo lunga») · dopo il 1º invio bozza rifiutata; dopo il 2º accettata e salvata
Prima richiesta	«Scrivi una lettera di disdetta per il servizio di telefono o internet, a partire da subito, da spedire con PEC.»

Campo	Esempio compilato
Griglia US01 (T1)	Servizio 1 · data di effetto 1 · modo di spedizione 1 · richiesta di brevità 0 → 3 su 4 = 75%. Barriera osservata: sottospecificazione (manca la brevità)
Solo T2	Non compilato: questa scheda è di T1
Solo T3	Non compilato: questa scheda è di T1
Interventi	10:16:30 · L2 · «Provi a ottenere una lettera più corta» · fermo da 60 s sulla bozza senza trovare «Non è quello che volevo»
Errori e difficoltà	Schermata Bozza: il pulsante «Non è quello che volevo» non è stato notato per 60 s · H6 (riconoscere anziché ricordare) · gravità 2
Citazioni	10:15:40 «Ma adesso la lettera la manda lei?» (equivoco sull'invio, collegato a H-03)
Domanda finale (US08)	«Forse non conosce il mio contratto» → codificata: limite indicato

Griglia di codifica di US01. Gli elementi attesi sono quattro, quelli dati dalla scheda: servizio, data di effetto, modo di spedizione, richiesta di brevità. Il punteggio è il numero di elementi presenti diviso per quattro. In Chiaro un campo lasciato «da decidere» conta come assente. Le quattro barriere sono quelle di E33 (prolissità, incompletezza, sovraspecificazione, sottospecificazione); la soglia di lunghezza oltre la quale una richiesta è prolissa si fissa nel pilota. Due codificatori lavorano separatamente su tutte le prime richieste, per quanto possibile senza sapere in quale condizione sono state prodotte (la frase di Chiaro è riconoscibile dal formato, quindi la cecità è solo parziale); l'accordo si misura con il kappa di Cohen (1960) e si risolvono i disaccordi discutendo.

9. Validità ecologica

L'ambiente riproduce i due contesti degli scenari di Design: un centro sociale con una persona accanto (Rosa, T1) e una cucina a casa con il tablet sul tavolo (Giuseppe, T2). Non riproduce l'uso nei giorni, e questo è il limite principale. Per T3 (Marta) riproduce solo la parte di Rosa, con Marta simulata sullo stesso tablet.

Aspetto	Nel test	Perché è simile all'uso reale	Minaccia
Luogo	Stanza tranquilla con un tavolo, sedia e luce normale; per T1 un familiare o l'osservatore seduto accanto	Scenari 1 e 2	Un rumore ambientale realistico (TV, voci) non c'è: la dettatura reale va provata con rumore moderato
Dispositivo	Tablet da circa 10 pollici, 1024 × 768, in	È il formato degli scenari	Il comportamento con la barra del browser (area visibile ridotta di 70–100 px) va verificato prima; la

Aspetto	Nel test	Perché è simile all'uso reale	Minaccia
	orizzontale		postura d'uso abituale si raccoglie con B15
Impostazioni	Il partecipante sceglie testo e contrasto, come farebbe a casa	Le impostazioni sono una funzione di Chiaro	—
Compiti	Disdetta di un abbonamento, domanda sul medico e avviso di pagamento, con dati inventati	Attività dell'Assignment 1	Gli scenari sono dati dalla scheda e non nascono da un'esigenza propria
Assistente e microfono	Simulati, Marta compresa (sezione 1)	—	La frase dettata è letta da una scheda e non spontanea; in T3 Marta è l'osservatore e il suggerimento è di copione
Durata	Circa 75 minuti	—	Non si osserva l'uso del giorno dopo (memoria, Taccuino)
Osservatore	Presente, con script di accoglienza	—	Effetto di sorveglianza e desiderabilità sociale: il valutatore è anche il progettista, il che può spingere i partecipanti a essere compiacenti

Interventi del valutatore come elemento esterno. Ogni intervento è registrato con livello, ora e parole usate (sezione 8). L1 non si conta; L2 e L3 sì, e il task che ne ha uno è segnato di conseguenza. I tempi si riportano sia per tutti i task sia per i soli task senza intervento. Un intervento non è mai usato per giudicare il design: se è stato necessario, è un problema registrato (euristica e gravità) e non un errore del partecipante.

Mitigazioni del bias del progettista. Script identico per tutti; nessuna spiegazione dell'interfaccia prima del task; domande della fase finale poste con la stessa formulazione; codifica di US01 anche da un secondo valutatore; soglie e ipotesi congelate prima della prima sessione.

10. Analisi dei risultati, copertura e replicabilità

L'analisi segue cinque passi, nell'ordine, e a fine studio si controlla che gli obiettivi siano stati coperti.

1. **Preparazione.** Una tabella per partecipante con le variabili della sezione 3; tempi dal cronometro, conteggi dal registro, punteggi SUS e TLX calcolati con le formule standard. Si segnalano i task con intervento e i dati censurati.

2. **Confronto tra condizioni.** Mediane e scarto interquartile per condizione; test di Wilcoxon a coppie per H0-1…H0-6 (sezione 6); correlazione per ranghi di coppie come dimensione dell'effetto.
3. **Confronto con le soglie.** Per ogni specifica si riporta il valore osservato e lo si legge rispetto a tre livelli, quelli di Whiteside, Bennett e Holtzblatt (1988) ripresi da Rosson e Carroll (2002): worst, il livello minimo accettabile (colonna «Minimo» della sezione 3); planned, l'obiettivo (colonna «Obiettivo»); best, il miglior valore possibile. Il best non è nella tabella della sezione 3 e si fissa qui, prima dei dati: dove la misura ha un limite naturale è quel limite (100% per US01, US04, US06, US07, US08, US09, US10, US11 e US15; 0 casi per US05; 0 interventi per US12; 1 invio per US03; SUS 100; NASA-TLX raw 0); per US02 è il tempo di un'esecuzione esperta di T1, cronometrata dal progettista prima della prima sessione e congelata con le soglie. Una specifica è «non verificata» sotto il worst, «verificata» tra worst e planned, «obiettivo raggiunto» da planned in su; la distanza dal best dice quanto margine resta. Per US14, H0-7 in aggiunta. Dove la chat libera permette la misura, la si riporta come livello attuale.
4. **Analisi qualitativa.** I commenti ad alta voce e gli errori si codificano per euristica (H1–H10, Nielsen, 1994) e gravità (0–4) e si collegano ai problemi H-01…H-16 del Design e P-1…P-28 della sezione 2 (tabella di raccordo nella stessa sezione) e ai W-1…W-13 del walkthrough (Design, Allegato A), per capire se sono confermati, nuovi o non osservati.
5. **Accordo tra codificatori.** Kappa di Cohen (1960) per la griglia di US01; accordo almeno sostanziale (kappa ≥ 0,6; Landis e Koch, 1977). Sotto questa soglia si ridefinisce la griglia e si ricodifica.

Copertura delle questioni di usabilità individuate (da verificare a fine studio)

Questione	Coperta da	Stato
Incompletezza e vaghezza della prima richiesta (C2, C3, C4)	US01, US03, H0-1	Coperta
Recupero dopo un risultato non voluto (C9)	US07	Coperta
Fiducia e limiti dichiarati (C6, C12)	US08	Coperta in parte: solo comprensione dichiarata
Errori di trascrizione (C13, C14)	US05	Coperta in parte: errore sempre segnalato
Chiusura naturale (C16)	US06	Coperta, con le frasi scritte
Memoria controllabile (C17, C18)	US10	Coperta, senza l'uso nei giorni
Verifica delle fonti e condivisione (C19…C27)	US09, US11	Coperta in parte: T3 solo su Chiaro e con Marta simulata; US16 non coperta
Aiuto per il tutor (H-06)	—	Non coperta
Metafore familiari (M2)	B14	Coperta dal questionario

Questione	Coperta da	Stato
Dettatura, controllo e chiusura (C10, C11, C15)	US05, US06	Coperta in parte: microfono simulato
Livelli di aiuto (C28)	—	Non coperta: il selettore non è attivo (P-7)
Consumo di calcolo (C29)	US03	Coperta in parte: indicatore indiretto
Standard visivi (C30)	US15	Coperta per ispezione, non con utenti

Replicabilità. Lo studio è replicabile perché sono fissati e allegati: la versione del prototipo (con data e identificativo della build), il testo dello script, le schede dei task e le combinazioni di ordine, i questionari, la scheda dell'osservatore, la griglia di codifica e il piano statistico. Il registro dell'applicazione si esporta come file di testo, un tocco per riga.

Pilota e modifiche. Tre partecipanti, esclusi dall'analisi, per controllare la comprensione delle schede, i tempi (e quindi il tetto di 10 minuti), la soglia di prolissità, il funzionamento del registro, il copione di Marta in T3 e la durata della sessione (circa 75 minuti). Dopo il pilota si ricalibrano le soglie al massimo una volta. Ogni modifica a questionari, schede o procedura si annota nella tabella seguente.

Data	Documento modificato	Che cosa cambia	Perché (osservato nel pilota)

11. Riferimenti e appendice

Le fonti dell'Assignment 1 (E#) e del Design sono riprese dai rispettivi documenti. Le citazioni qui sotto sono a memoria, senza numeri di pagina, e vanno ricontrollate sui testi prima della consegna.

- Brooke, J. (1996). SUS: A "quick and dirty" usability scale. In Jordan, P. W. et al. (Eds.), Usability Evaluation in Industry. Taylor & Francis.
- Cohen, J. (1960). A coefficient of agreement for nominal scales. Educational and Psychological Measurement, 20(1).
- Dahlbäck, N., Jönsson, A., Ahrenberg, L. (1993). Wizard of Oz studies: why and how. Knowledge-Based Systems, 6(4), 258–266.
- Hart, S. G., Staveland, L. E. (1988). Development of NASA-TLX: Results of empirical and theoretical research. In Hancock, P. A., Meshkati, N. (Eds.), Human Mental Workload. North-Holland.
- Holm, S. (1979). A simple sequentially rejective multiple test procedure. Scandinavian Journal of Statistics, 6(2).
- ISO/IEC (2001). ISO/IEC 9126-1: Software engineering – Product quality – Part 1: Quality model. International Organization for Standardization.
- Kelley, J. F. (1984). An iterative design methodology for user-friendly natural language office information applications. ACM Transactions on Office Information Systems, 2(1), 26–41.

- Kerby, D. S. (2014). The simple difference formula: An approach to teaching nonparametric correlation. Comprehensive Psychology, 3.
- Landis, J. R., Koch, G. G. (1977). The measurement of observer agreement for categorical data. Biometrics, 33(1).
- Nielsen, J. (1994). Enhancing the explanatory power of usability heuristics. CHI '94.
- Nielsen, J., Landauer, T. K. (1993). A mathematical model of the finding of usability problems. INTERCHI '93.
- Rosson, M. B., Carroll, J. M. (2002). Usability Engineering: Scenario-Based Development of Human-Computer Interaction. Morgan Kaufmann.
- Sauro, J., Lewis, J. R. (2016). Quantifying the User Experience: Practical Statistics for User Research (2nd ed.). Morgan Kaufmann.
- W3C (2023). Web Content Accessibility Guidelines (WCAG) 2.2. W3C Recommendation.
- Whiteside, J., Bennett, J., Holtzblatt, K. (1988). Usability engineering: Our experience and evolution. In Helander, M. (Ed.), Handbook of Human-Computer Interaction. North-Holland.
- Wilcoxon, F. (1945). Individual comparisons by ranking methods. Biometrics Bulletin, 1(6).

Appendice: affermazioni del SUS (traduzione provvisoria), a cinque gradi da «per niente d'accordo» a «molto d'accordo».

1. Penso che mi piacerebbe usare spesso questo sistema.
2. Ho trovato il sistema inutilmente complesso.
3. Ho trovato il sistema facile da usare.
4. Penso che avrei bisogno dell'aiuto di una persona esperta per usarlo.
5. Ho trovato le varie funzioni ben integrate tra loro.
6. Ho trovato troppe incoerenze nel sistema.
7. Penso che la maggior parte delle persone imparerebbe a usarlo molto in fretta.
8. Ho trovato il sistema molto macchinoso da usare.
9. Mi sono sentito/a molto sicuro/a nell'usare il sistema.
10. Ho dovuto imparare molte cose prima di riuscire a usarlo.

Punteggio: per le affermazioni dispari, risposta meno 1; per le pari, 5 meno la risposta; somma moltiplicata per 2,5 (Brooke, 1996).